

Segmentacja – zastosowanie metod ML do analizy zdjęć eksperymentalnych

I. Wstęp



Celem projektu jest zastosowanie metod nauczania maszynowego do analizy rzeczywistych danych – obrazów uzyskanych w eksperymencie. Zadanie będzie opierało się na problemie segmentacji obrazu, a rozwiązaniem będzie zbudowanie kilku sieci konwolucyjnych i porównanie ich działania.

II. Narzędzia

W projekcie wykorzystano dane eksperymentalne, dane bazy online o wolnym dostępie i wytrenowane już modele.

1. Zbiór testowy

Dzięki uprzejmości Zakładu Biofizyki i Biologii Nowotworów otrzymano dane obrazowe zawierające zdjęcia mikroskopowe dwuwymiarowe. Oczywiście te dane nie zawierają własnych maskowanych danych treningowych. Poniżej przykładowe zdjęcia 00001 (zdj. 1) i 00023 (zdj. 2), dobrane by przedstawić ich różnorodność i złożoność zadania.



Zdjęcie 1 A01 POINT 00001 SCAN 00001 00001 **Zdjęcie 2** A01 POINT 00001 SCAN 00023 00001

Eksperymentalne dane będą dość trudne do pracy, ponieważ są dość zróżnicowane, lecz nie są liczne: 2 hodowle po 3 powtórzenia po 4 pomiary po 23 zdjęcia, czyli $2 \times 3 \times 4 \times 23 = 552$ zdjęcia.

2. Zbiór treningowy i walidacyjny

„Kaggle Data Science Bowl 2018” to publiczny zestaw obrazów mikroskopowych, którego głównym zadaniem było segmentowanie jąder komórkowych w 2D – dane pochodzą z różnych eksperymentów, barwień, techników i laboratoriów, więc są bardzo zróżnicowane pod kątem technicznych warunków pobrania [1][5]. Zaznaczenie jąder nie jest dokładnie naszym zagadnieniem, ale jest wystarczające do próby wstępnej analizy w zakresie projektu. Dane z Kaggle raczej nie pozwolą uzyskać doskonałych wyników, ale raczej modelowi poznać ogólne cechy.

3. Uwagi wstępne

Podejściem zastosowanym w tym projekcie będzie *transfer learning*, który polega na wykorzystaniu wyuczonych wag do modelu zamiast uczenia nowej sieci od zera w wypadku, gdy rozwiązywane problemy są stosunkowo podobne.


Pewnym problemem może okazać się ewaluacja otrzymanych wyników. Nasze dane nie mają masek, więc sprawdzenie dokładności dopasowania lub jakości segmentacji będzie musiała polegać na obserwacji procesu uczenia oraz wizualnej ocenie obrazów i masek.

III. Metody i wyniki

Na początku projektu załadowano oba zbiory danych i zbudowano bardzo prostą sieć U-net złożoną z 2 encoderów złożonych z 1->8->16 warstw i dwóch decoderów, MaxPool2d oraz funkcji aktywacji ReLU. Dwa etapy kodowania są konieczne, ponieważ komórki mają kontekst przestrzenny i mogą się stykać. Wejście to pojedynczy kanał grayscale, a na wyjściu znajduje się funkcja sigmoid.


a) Dane pierwszego treningu

Pierwszy trening obejmował 5 epok uczenia, optymalizator Adam, funkcję kosztu jako połączenie $0.5BCE + 0.5DICE$ [2][3]. Wyniki na rys. 1.



Rysunek 1. Wizualizacja: zdjęcie, przewidziana maska, nałożenie maski na obraz. Wylosowało się dość trudne zdjęcie pełne komórek i maska nie poradziła sobie za dobrze. Na tym etapie modelowi opłaca się zaznaczyć cały obszar jako tło.

- b) Dane drugiego treningu takie same jak treningu pierwszego, tylko więcej epok uczenia – 10. Wyniki na rys. 2.



Rysunek 2. Wyniki drugiego treningu. Dalsze zwiększanie liczby epok nie poprawiało sytuacji. Mogło nastąpić przeuczenie.

c) StarDist

W tym miejscu potrzebna była zmiana podejścia. Wykorzystano model wytrenowany na podobnych do naszych obrazach o nazwie Stardist [4]. Celem było otrzymanie na wyjściu dobrze opisanej maski i później dodanie jej wraz z obrazami do zbioru treningowego, co miało wpłynąć pozytywnie na wyniki badanej sieci U-net.

Znaczną częścią pracy stanowiła próba poprawnej instalacji i załadowania modelu, co nie doszło ostatecznie do skutku.


d) Cellpose

Problemem ze StarDist była głównie niezgodność wersji pomiędzy paczkami i wybrakowane importowanie bibliotek na komputer stacjonarny. Zdecydowano zatem spróbować innego modelu. Pomimo wypróbowania różnych wersji wytrenowanego Cellpose, żadna z nich nie wykonała obliczeń na pojedynczym obrazie szybciej niż kilka godzin. To sprawia, że model jest bezużyteczny w „warunkach domowych”.

e) Dodanie do modelu zdjęć z naszego eksperymentu wraz z maskami

Te niepowodzenia jednak pozwoliły na wykorzystanie jednego z powyższych modeli w nieco inny sposób. Na stronie demo Cellpose [6] jest możliwość ręcznego wgrania po jednym zdjęciu i, po wykonaniu krótkich obliczeń online, otrzymania maski. Tak zrobiono z kilkoma obrazami i zapisano je do odpowiednich katalogów w folderze z danymi Kaggle (rys. 3.).

Te, odpowiednio ułożone, obrazy oraz maski zostały dopasowane do struktury zbioru Kaggle DSB 2018, aby umożliwić ich bezpośrednie wykorzystanie w istniejącym pipeline treningowym kolejnych struktur sieci.



Rysunek 3. Przykładowe zdjęcie testowe będące wejściem do Cellpose online (a), wyjście programu (b) oraz zapisana do pliku maska (c).


f) Powrót do trenowania modelu U-net

Do tej pory bardzo podstawowe parametry modelu mogły powodować niestabilny BCEDice i szybki overfitting. Dokonano zatem stopniowo pewnych, bardziej znaczących, zmian:

1. Zmiana **ReLU** na **LeakyRelu(0.1)** – w przeciwieństwie do ReLu, LeakyReLU daje gradient zawsze, co może zapewnić lepsze maski na słabym kontraście.
2. Liczba **stanów ukrytych z 16 do 32** - więcej stanów ukrytych przy zachowaniu liczby warstw
3. Dodanie **dropout 20%** tylko w encoderze - potrzebny, ponieważ obrazy są do siebie podobne, dodatkowo dropout stabilizuje Dice.
4. Dodatkowy parametr w optymalizatorze **weight_decay** - regularyzacja L2, poprawi generalizację
5. Modyfikacja funkcji kosztu

BCEDice działa po pikselu, ale przy dużej przewadze tła model ma skłonność zaznaczania wszystkiego jako tło. Rozwiązaniem tego problemu może być zastosowanie zamiast BCE


funkcji Focal[10]. Stosowana jest ona szczególnie w segmentacji obrazów z bardzo małymi elementami [7][8]. Wyniki sieci U-net z tą funkcją kosztu na rys. 4.



Rysunek 4. Najlepszy z wyników prostej sieci U-net z FocalDiceLoss jako funkcją kosztu.

g) Nowa sieć: Mini-U-Net ze skip connections i FocalDiceLoss


W związku z tym, że poprzednie zmiany nie dały wielkiej różnicy, zmieniono model na Mini-U-Net ze skip connections, które umożliwiają łączenie informacji o szczegółach z kontekstem całego obrazu. Mini-U-net jest znacznie lżejszy obliczeniowo od StarDist lub Cellpose, ale nadal wykorzystuje skip connections. [9] Pomysł okazał się sukcesem, działa znacznie szybciej i dał pozytywne wyniki (rys. 5.).



Rysunek 5. Najlepszy z wyników prostej sieci U-net z FocalDiceLoss jako funkcją kosztu.

h) U-net sieć głęboka + FocalDiceLoss

Dane z sieci mini okazały się dość dobre, a sieć działa na tyle szybko, że podjęto próbę jej rozbudowania. Encoder złożony z trzech bloków konwolucyjnych, w których liczba kanałów rośnie kolejno: 32 -> 64 -> 128, dodatkowo normalizacja. Tzw. "bottleneck" to najgłębsza część sieci, o największej liczbie kanałów (256). Odpowiada ona za ekstrakcję najbardziej abstrakcyjnych reprezentacji obrazu. Dekoder - 3x upsampling (ConvTranspose2d) + łączenie cech skip connections.




Rysunek 6. Najlepsze z wyników tego projektu. Pokazane więcej zdjęć w celu zobrazowania jak model radzi sobie z różnorodnymi obrazami.

Długie uczenie (10 epok) oraz optymalne połączenie głębokości sieci z funkcją kosztu pozwoliło na uzyskanie bardzo dobrych wyników (rys. 6.). Na koniec uzyskane maski zapisano do plików w odpowiedniej, uporządkowanej strukturze.

- i) U-net sieć głęboka + Tversky Loss jest uogólnieniem Dice Loss, które pozwala szczególnie karać false positives i false negatives.

Uzyskano obrazy, na których większą część stanowią rozpoznane komórki niż tło. W przypadku innych, testowanych tu, funkcji kosztu nie uzyskiwało się zazwyczaj tyle fałszywych pozytywów (rys. 7.) a raczej fałszywe negatywy.



Rysunek 7. Najciekawszy wynik z tej sieci, zauważalne fałszywe pozytywy.

IV. Wnioski

Celem przeprowadzonych eksperymentów było zbadanie wpływu architektury sieci oraz zastosowanej funkcji straty na jakość segmentacji komórek.

Przetestowanych zostało wiele klika sieci i parametrów. W niektórych następowało przeuczenie, spowodowane prawdopodobnie stosunkowo małym zbiorem danych. W większości uczenie można było przerywać między 5 a 10 epoką.

Przeprowadzenie kolejno badań (tab.1) pokazało generalną poprawę w parametrach i zdecydowaną poprawę w ocenie wizualnej uzyskanych masek.

Tabela 1 Porównanie metod i parametrów poszczególnych prób oraz ich ostatecznych wartości funkcji kosztu.

Parametry sieci	Koszt na zbiorze treningowym	Koszt na zbiorze walidacyjnym	Koszt na zbiorze testowym
Prosty U-net 5 epok	TrainLoss=0.2933,	ValLoss=0.2919,	Dice=0.7151
Prosty U-net 10 epok	TrainLoss=0.8143,	ValLoss=0.8219,	Dice=0.6591
stanów ukrytych 32	TrainLoss=0.3107,	ValLoss=0.3521,	Dice=0.6959
Dropout+weight_decay	TrainLoss=0.3614,	ValLoss=0.3271,	Dice=0.6911
FocalDiceLoss	TrainLoss=0.5562,	ValLoss=0.5258,	FocalDiceLoss=0.6798
Mini-U-net ze skip connections + FocalDiceLoss	TrainLoss=0.3367,	ValLoss=0.3314,	FocalDiceLoss=0.7777
U-net 2 epoki + FDL	TrainLoss=0.4430,	ValLoss=0.3828,	FocalDiceLoss=0.7098
U-net 10 epok + FDL	TrainLoss=0.2977,	ValLoss=0.3714,	FocalDiceLoss=0.7175

U-net sieć głęboka + Tversky Loss 10 epok	TrainLoss=0.1508,	ValLoss=0.2503,	TverskyLoss=0.5706
---	-------------------	-----------------	--------------------

W przypadku prostego U-Netu trenowanego przez 5 epok uzyskano relatywnie dobre i stabilne wyniki, przy niskiej wartości funkcji kosztu zarówno na zbiorze treningowym, jak i walidacyjnym, oraz współczynniku BCEDice na poziomie 0.7151. Wydłużenie treningu do 10 epok spowodowało prawdopodobnie przeuczenie modelu i pogorszenie zdolności generalizacji.

Zwiększenie liczby stanów ukrytych do 32 poprawiło model, jednak BCEDice (0.6959) pozostało porównywalne z prostszymi konfiguracjami.

Zastosowanie regularyzacji w postaci dropout oraz weight_decay doprowadziło do stabilizacji uczenia i zmniejszenia różnicy między stratą treningową a walidacyjną. Mimo to nie zaobserwowano istotnej poprawy jakości segmentacji. W tym przypadku ograniczeniem była prawdopodobnie architektura sieci.

Wprowadzenie funkcji straty FocalDiceLoss pozwoliło lepiej uwzględnić problem niezbalansowanych klas (tło a obiekt), jednak w połączeniu z prostą architekturą U-Net nie przełożyło się to na znaczący wzrost jakości segmentacji. Wyniki te wskazują, że sama zmiana funkcji straty nie jest wystarczająca bez odpowiednio dopasowanej architektury.

V. Podsumowanie

Przeprowadzone eksperymenty wskazują, że największy wpływ na jakość segmentacji miało połączenie odpowiedniej architektury (U-net + skip connections) z funkcją straty (FocalDiceLoss) dostosowaną do niezbalansowanych danych. Zwiększanie liczby parametrów lub czasu treningu bez zmiany struktury nie daje lepszej segmentacji.

VI. Źródła

[1] <https://www.kaggle.com/competitions/data-science-bowl-2018/data>

[2] <https://bbbc.broadinstitute.org/BBBC038/>

[3] <https://cvinvolution.medium.com/dice-loss-in-medical-image-segmentation-d0e476eb486>

[4] https://github.com/stardist/stardist/tree/main/models/paper/2D_dsb2018

[5] Caicedo, J.C., Goodman, A., Karhohs, K.W. *et al.* Nucleus segmentation across imaging experiments: the 2018 Data Science Bowl. *Nat Methods* **16**, 1247–1253 (2019).

<https://doi.org/10.1038/s41592-019-0612-7>

[6] <https://www.cellpose.org/>

[7] <https://medium.com/codex/step-by-step-guide-implementing-focal-loss-in-nnu-net-with-weighted-dice-and-bce-losses-44c5692a5e94>

[8] Michael Yeung, Evis Sala, Carola-Bibiane Schönlieb, Leonardo Rundo, *Unified Focal loss: Generalising Dice and cross entropy-based losses to handle class imbalanced medical image segmentation*, Computerized Medical Imaging and Graphics, Volume 95, 2022, 102026, ISSN 0895-6111, <https://doi.org/10.1016/j.compmedimag.2021.102026>.

[9] Javed, S., Khan, T. M., Qayyum, A., Alinejad-Rokny, H., Sowmya, A., & Razzak, I. (2024). Advancing Medical Image Segmentation with Mini-Net: A Lightweight Solution Tailored for Efficient Segmentation of Medical Images. arXiv preprint arXiv:2405.17520 [eess.IV]. <https://doi.org/10.48550/arXiv.2405.17520>

[10] <https://medium.com/codex/focal-loss-in-medical-image-segmentation-enhancing-small-structure-detection-4ded164caa89>